Pronóstico y alertas de demanda eléctrica

Caso de análisis: Tétouan, Marruecos

Juan Camilo Sánchez Navarro

Resumen ejecutivo

La planificación de una red eléctrica requiere anticipar la demanda y reconocer con tiempo los periodos de consumo elevado. En Marruecos, la demanda nacional llegó a 49 TWh en 2025 y el máximo de potencia alcanzó 8.400 MW en julio de 2026 (Ministère de l'Économie et des Finances du Royaume du Maroc, 2026). En Tétouan, la empresa distribuidora Amendis describe inversiones para ampliar y reforzar la red y atender problemas de sobrecarga y caídas de tensión (Amendis, s. f.). Este proyecto propone desarrollar un prototipo que pronostique el consumo de tres zonas de Tétouan, estudie el valor de las variables meteorológicas y genere señales de demanda estadísticamente elevada. La solución combinará modelos de series temporales, modelos de regresión y una clasificación de picos, con evaluación cronológica, ejecución programada en AWS y visualización en Power BI. La base principal corresponde a 2017, por lo que la validación se concentrará en periodos históricos y la actualización meteorológica se distinguirá de la medición de consumo eléctrico actual. El resultado esperado es una herramienta reproducible que permita comparar modelos, anticipar periodos de demanda elevada y comunicar con claridad la incertidumbre y los límites de cada alerta.

Palabras clave: demanda eléctrica, pronóstico, series temporales, variables meteorológicas, alertas de demanda, AWS, Power BI.

1. Planteamiento del problema y justificación del proyecto

El valor del pronóstico eléctrico está en ayudar a preparar la operación de la red antes de que aparezcan condiciones de demanda exigentes. La demanda total y su distribución a lo largo del día condicionan la planificación, el uso de la infraestructura y la atención de periodos que pueden requerir seguimiento. Por eso, una predicción útil debe mostrar cuánto consumo se espera, cuándo puede ocurrir el máximo y qué tan incierta es la estimación.

1.1. Contexto energético de Marruecos

La demanda eléctrica nacional de Marruecos ha aumentado y los máximos recientes muestran la importancia de anticipar periodos de carga elevada. La Oficina Nacional de Electricidad y Agua Potable informó que la demanda alcanzó 45.713 GWh en 2024, un 3,9 % más que el año anterior, con un pico de 7.580 MW. En 2025, la demanda llegó a 49 TWh y el pico fue de 7.990 MW. En julio de 2026 se registró un máximo de 8.400 MW (Ministère de l'Économie et des Finances du Royaume du Maroc, 2025, 2026). Estas cifras describen el sistema nacional, no el comportamiento específico de Tétouan, pero sitúan el proyecto dentro de una necesidad amplia de planificación de la demanda.

La transición energética también aumenta la importancia de entender las condiciones y límites de las redes. En enero de 2026, la Autoridad Nacional de Regulación de la Electricidad de Marruecos publicó la capacidad de acogida de las redes de transporte y distribución para integrar energías renovables durante el periodo comprendido entre 2026 y 2030, con una capacidad nacional acumulada de 10.429 MW (Autorité Nationale de Régulation de l'Électricité, 2026). Este dato no implica que el pronóstico de consumo resuelva por sí mismo la integración renovable, pero confirma que la planificación de la red es una actividad relevante en el sector eléctrico marroquí.

1.2. Contexto de Tétouan y decisión operativa

El caso local debe situarse en la distribución eléctrica, no en la operación de una central generadora. Amendis describe que la energía que distribuye en Tánger y Tétouan proviene de la ONEE y que la red de Tétouan se alimenta mediante cuatro subestaciones de origen. La empresa también identifica un centro de control en Tétouan y trabajos para ampliar la red de media tensión, instalar puestos de distribución y reforzar o renovar redes de baja tensión frente a problemas de sobrecarga y caídas de tensión (Amendis, s. f.).

Esta información permite formular una necesidad concreta para un prototipo analítico. Un equipo responsable de planificar o vigilar una red de distribución podría beneficiarse de conocer con anticipación las horas en las que se espera un consumo elevado y revisar qué tan confiable resulta esa señal. Sin datos de capacidad por zona, mediciones de tensión, topología, registros de incidentes o criterios internos de operación, el modelo no puede declarar que habrá una sobrecarga ni recomendar maniobras de red. La solución se limitará a pronosticar la demanda y señalar situaciones que merecen revisión.

El usuario de referencia será un analista de planificación u operación de demanda, definido como una persona que necesita examinar el consumo por zona y prepararse para periodos de mayor demanda. El dashboard deberá permitirle responder tres preguntas operativas: en qué momento se espera el máximo, cuánto podría superar un umbral definido y qué tan confiable ha sido una alerta semejante en las pruebas históricas.

1.3. Datos disponibles y límites de su aplicación

El dataset público Power Consumption of Tetouan City ofrece una base adecuada para estudiar patrones temporales y evaluar el aporte del clima al pronóstico. La ficha de UCI documenta registros cada diez minutos, tres variables de consumo por zona y variables ambientales como temperatura, humedad, velocidad del viento y flujos solares difusos (Salam & El Hibaoui, 2018b). La frecuencia permite analizar ciclos diarios y semanales y después construir pronósticos horarios para un horizonte de hasta siete días, sujeto a la validación del modelo.

La auditoría del archivo local encontró 52.416 registros entre el 1 de enero de 2017 y el 30 de diciembre de 2017. Esto deja fuera el último día del año y difiere de la cantidad reportada en la ficha de UCI. La discrepancia deberá resolverse o documentarse antes de congelar el conjunto analítico. Además, un único año permite estudiar patrones intradiarios y semanales, pero no permite medir de forma independiente la variación entre años ni validar directamente la demanda actual de Tétouan.

La población y el área de servicio tampoco deben tratarse como equivalentes. Las estadísticas territoriales de 2024 sitúan la población de la prefectura de Tétouan en 611.928 habitantes (Observatoire Régional de Veille Stratégique et d'Intelligence Territoriale, 2026). Amendis informa una población servida de 765.227 personas para su perímetro de Tétouan (Amendis, s. f.). Las cifras reflejan delimitaciones o definiciones diferentes y no deben compararse directamente sin revisar su geografía. Tampoco sería defendible multiplicar el consumo de 2017 por el crecimiento de la población para fabricar una demanda actual. La antigüedad de los datos limita la interpretación a una evaluación histórica, y esa limitación debe quedar visible en el producto final.

1.4. Problema central y pregunta de negocio

El problema central consiste en determinar si un sistema de pronóstico, evaluado con datos que respeten el orden temporal, puede anticipar periodos de demanda estadísticamente elevada y comunicar esa información de forma clara. El prototipo comparará modelos que utilizan el consumo histórico con modelos que incorporan calendario y variables meteorológicas disponibles al emitir la predicción. Las alertas se tratarán como señales de demanda elevada y no como confirmaciones de riesgo eléctrico, porque el dataset no incluye límites de capacidad de la red.

La pregunta que guía el proyecto es la siguiente: ¿cómo desarrollar y evaluar un sistema reproducible que pronostique la demanda eléctrica horaria de las zonas de Tétouan, determine si las variables meteorológicas mejoran la predicción y genere alertas cuantificadas de demanda elevada para facilitar la revisión anticipada de periodos exigentes?

2. Antecedentes

La investigación sobre el dataset de Tétouan ya ha comparado múltiples técnicas de pronóstico y ha explorado la combinación de consumo, clima y métodos de aprendizaje automático. La revisión disponible indica que la contribución de este proyecto no puede consistir únicamente en probar algoritmos conocidos, sino en construir una evaluación coherente con el momento real en que se pronostica y conectar los resultados con alertas y una solución automatizada.

2.1. Estudio original del dataset

Salam y El Hibaoui (2018a) compararon regresión lineal, árboles de decisión, Random Forest, Support Vector Regression y redes neuronales feedforward. El trabajo estudió pronósticos a diez minutos y a una hora, ajustó hiperparámetros mediante búsqueda en cuadrícula y evaluó los errores con MAE y RMSE. Los autores reportaron que Random Forest obtuvo los menores errores entre las alternativas comparadas en sus experimentos. Por ello, una comparación similar sin un protocolo adicional no sería suficiente para diferenciar la propuesta.

La fuente de datos está publicada en UCI bajo licencia CC BY 4.0, que permite reutilizarla con la atribución correspondiente (Salam & El Hibaoui, 2018b). La versión disponible contiene las tres series de consumo y cinco variables ambientales además de la marca temporal. La revisión del archivo local, sin embargo, detectó una diferencia de cobertura que debe tratarse de forma explícita antes de la modelación.

2.2. Investigación sobre pronóstico, clima y patrones de consumo

Alsalem (2025) integró agrupamiento difuso con modelos de aprendizaje automático para estimar el consumo de Tétouan. El estudio evaluó Random Forest, Support Vector Machine, K Nearest Neighbors, XGBoost y perceptrón multicapa, y reportó una mejora al incorporar la agrupación difusa. Este antecedente demuestra que la combinación de agrupamiento y predicción ya se ha estudiado con los mismos datos, por lo que no se incluirá como una contribución asumida del proyecto.

Benhayoun y Lakouismi (2026) compararon regresión múltiple, SVM, XGBoost, ARIMA y SARIMA con variables climáticas y agrupamiento temporal. El resumen del estudio reporta un mejor desempeño de XGBoost dentro de los métodos evaluados, mientras que SARIMA capturó patrones estacionales. El resultado refuerza la necesidad de comprobar el desempeño empírico en lugar de seleccionar de antemano una familia de modelos.

Biswas, Mahdi y Das Gupta (2026) aplicaron el marco Darts para comparar regresión lineal, Random Forest, Prophet, TiDE y TSMixer con el dataset de Tétouan. El estudio incluyó datos a diez minutos y horarios, técnicas de escalado y división cronológica entre entrenamiento y prueba. También señala un riesgo relevante para este proyecto: evaluar un modelo con clima observado en el futuro puede producir una estimación demasiado optimista, ya que esas condiciones no se conocen al emitir el pronóstico.

2.3. Brecha aplicada y enfoque de la propuesta

La literatura consultada cubre comparaciones de modelos, variables meteorológicas y, en algunos casos, agrupamiento. En las descripciones y resultados revisados no se ha identificado una evaluación conjunta que conecte el pronóstico con una regla explícita para detectar demanda elevada, mida falsas alarmas y eventos omitidos, y documente un flujo automatizado que publique resultados trazables en un dashboard. Esta es una brecha aplicada que el proyecto explorará, no una afirmación de novedad científica global.

La propuesta evaluará modelos de series temporales y modelos de regresión sobre periodos de prueba equivalentes. También definirá una etiqueta de demanda elevada sin utilizar información futura, medirá el desempeño de las alertas y demostrará la ejecución programada del flujo de datos. La revisión bibliográfica deberá profundizar en los protocolos exactos, horizontes y métricas de cada artículo antes de fijar definitivamente la contribución del proyecto.

3. Objetivos

3.1. Objetivo general

Desarrollar y evaluar un prototipo reproducible para pronosticar la demanda eléctrica horaria de las tres zonas del dataset de Tétouan, estimar la utilidad predictiva de las variables meteorológicas y generar alertas cuantificadas de demanda elevada mediante un pipeline automatizado en AWS y un dashboard en Power BI.

3.2. Objetivos específicos

- Caracterizar la calidad, la cobertura y los patrones temporales del dataset, y definir una unidad de análisis y una agregación coherentes con el horizonte de pronóstico.
- Comparar modelos de series temporales y modelos de regresión mediante validación cronológica, y cuantificar el aporte de las variables de calendario y meteorología.

- Construir y evaluar una clasificación experimental de demanda estadísticamente elevada, midiendo alertas correctas, falsas alarmas, eventos omitidos y magnitud del exceso previsto.
- Implementar un flujo programado que procese datos meteorológicos, ejecute los modelos y almacene resultados trazables para su visualización en Power BI.
- Evaluar el desempeño predictivo y funcional del prototipo, y documentar las condiciones necesarias para una eventual aplicación con mediciones eléctricas actuales.

4. Solución propuesta

La solución será un prototipo de análisis y pronóstico para un analista de planificación u operación de una red de distribución eléctrica. La herramienta mostrará la demanda histórica y pronosticada por zona, la incertidumbre de la predicción y las horas en las que el consumo previsto supera un umbral estadístico. El flujo automatizado actualizará las variables meteorológicas y los resultados del modelo, pero diferenciará esas actualizaciones de la medición de consumo eléctrico real.

4.1. Modelos y salidas analíticas

El notebook maestro comparará una referencia de persistencia, referencias naive estacionales diaria y semanal, y AutoARIMA mediante la función auto.arima() del paquete forecast en R. La selección de los órdenes ARIMA será automática y se registrarán la configuración, el modelo seleccionado, los residuos y los intervalos de pronóstico. Como competidores se evaluarán modelos de regresión con machine learning, como Random Forest o HistGradientBoosting, cuando exista una justificación analítica. La comparación se realizará por zona y horizonte sobre los mismos orígenes temporales.

La clasificación de demanda elevada utilizará una variable binaria derivada del consumo. Como referencia inicial se evaluará el percentil 95 de cada zona, calculado exclusivamente con los datos de entrenamiento de cada partición. Se medirán precision, recall, F1, PR-AUC y falsas alarmas. Esta etiqueta identifica valores altos respecto al histórico y no representa una sobrecarga real ni un límite técnico de la red. La magnitud del exceso se calculará con el pronóstico numérico respecto al umbral estadístico.

El dashboard tendrá una vista principal con demanda observada, pronóstico e intervalo de incertidumbre, junto con marcadores para las horas con alerta. Una segunda vista permitirá comparar las tres zonas, y una tercera presentará el error histórico, el sesgo del pronóstico y el desempeño de las alertas. El mapa solo representará las zonas como áreas geográficas si se obtienen límites espaciales fiables, ya que las etiquetas Zone 1, Zone 2 y Zone 3 no aportan por sí mismas sus polígonos.

4.2. Requerimientos del prototipo

Los requerimientos describen qué deberá hacer la solución y permitirán comprobar su utilidad durante las pruebas. Las metas numéricas de precisión se fijarán después de evaluar las líneas base, para evitar elegir umbrales arbitrarios.

ID	Requerimiento
R1	Generar pronósticos horarios por zona para un horizonte de hasta siete días, sujeto a validación histórica.
R2	Comparar líneas base, modelos temporales y regresores con consumo anterior, calendario y clima disponible.
R3	Evaluar el aporte del clima sin usar variables que no se conocían al emitir la predicción.
R4	Señalar horas de demanda elevada e indicar la demanda prevista y el exceso frente al umbral.
R5	Mostrar incertidumbre, error histórico y última actualización, distinguiendo datos históricos y pronósticos experimentales.
R6	Automatizar consulta meteorológica, inferencia y almacenamiento con trazabilidad de datos, modelo y ejecución.

Tabla 1. Requerimientos del prototipo

4.3. Restricciones y factibilidad

El alcance del prototipo está condicionado por la cobertura temporal y las variables presentes en la fuente. Las principales restricciones son las siguientes:

- El archivo local contiene 52.416 registros hasta el 30 de diciembre de 2017, mientras que la ficha de UCI reporta 52.417 instancias. La diferencia deberá resolverse o documentarse antes de fijar los datos definitivos.
- Un solo año permite analizar ciclos diarios y semanales, pero no valida la variación entre años ni permite afirmar que el modelo pronostica correctamente la demanda de 2026.
- No se dispone de mediciones eléctricas actuales de Tétouan ni de límites técnicos por zona. Las alertas serán estadísticas y no confirmarán riesgo de sobrecarga.
- No se dispone de polígonos geográficos fiables para las tres zonas. El mapa deberá limitarse a una referencia de la ciudad o a una selección por zona hasta que se consigan geometrías verificadas.
- Los datos históricos incluyen el clima observado, pero no los pronósticos meteorológicos que se conocían en cada instante de 2017. Por tanto, la evaluación con clima observado se reportará por separado de la evaluación operativa posible.
- La actualización de Open Meteo no equivale a actualizar el consumo real. Una aplicación operativa exigiría una fuente autorizada y reciente de mediciones eléctricas.

4.4. Criterios de calidad metodológica y técnica

La dirección del proyecto utilizará un enfoque adaptado del PMI para gestionar inicio, planificación, ejecución, seguimiento y control, y cierre. El desarrollo analítico seguirá CRISP-DM, con comprensión del negocio, comprensión de los datos, preparación, modelado, evaluación y despliegue. El alcance, el cronograma, los riesgos, los criterios de aceptación y las decisiones se documentarán en un plan de gestión específico.

La evaluación respetará el orden cronológico y utilizará validación de origen móvil. En cada origen, el entrenamiento contendrá únicamente observaciones anteriores y los pronósticos cubrirán 24 o 168 horas. Todos los candidatos se medirán sobre las mismas fechas. El periodo de diciembre de 2017 ya fue inspeccionado en una evaluación anterior, por lo que no se tratará como un conjunto de prueba intacto para nuevas selecciones. Los predictores deberán estar disponibles al momento de emitir cada pronóstico.

El código y las transformaciones se versionarán en GitHub, mientras que el archivo original permanecerá sin cambios. Los datos de UCI se reutilizarán con la atribución requerida por su licencia CC BY 4.0. En AWS se utilizarán permisos mínimos, registros de ejecución y recursos proporcionales al tamaño del proyecto.

5. Metodología

La dirección del proyecto se organizará con los grupos de procesos de inicio, planificación, ejecución, seguimiento y control, y cierre. En la planificación se establecerán el Project Charter, el alcance, la estructura de desglose del trabajo, el cronograma, las dependencias, los criterios de aceptación, los riesgos y los recursos. El desarrollo técnico seguirá CRISP-DM, que permite ordenar las actividades analíticas y volver a fases anteriores cuando la evidencia lo requiera.

El análisis se documentará en un único notebook maestro con las seis fases de CRISP-DM. Se inspeccionarán las variables, unidades, marcas de tiempo, cobertura y valores extremos. Luego se analizarán los perfiles por zona, los patrones temporales y las relaciones con las variables meteorológicas. La serie horaria se mantendrá como candidata hasta confirmar el significado físico de la variable de consumo.

El pronóstico se comparará mediante naive de persistencia, naive estacional diaria y semanal, AutoARIMA y modelos de regresión con machine learning. AutoARIMA seleccionará automáticamente sus órdenes mediante forecast::auto.arima() en R. Se utilizarán MAE, RMSE y WAPE, con resultados por zona y horizonte. El análisis de regresores distinguirá variables conocidas en el origen de predicción de observaciones meteorológicas registradas posteriormente.

La clasificación de demanda elevada se desarrollará como un problema independiente del pronóstico numérico. El umbral estadístico se calculará solo con datos de entrenamiento y las métricas incluirán precision, recall, F1, PR-AUC y tasa de falsas alarmas. La señal se interpretará como demanda alta respecto al histórico y no como una confirmación de capacidad insuficiente de la red.

Una vez validado localmente, el código se organizará para ejecutar la preparación, los modelos de Python y AutoARIMA en un script R llamado desde el notebook. El pipeline generará resultados estructurados para Power BI. AWS se incorporará después de validar la ejecución local y confirmar una fuente de demanda reciente. S3, EventBridge Scheduler, Lambda o un contenedor, CloudWatch y Athena se evaluarán según los requisitos reales. Actualizar meteorología no equivale a actualizar mediciones eléctricas.

Objetivo	**Actividades principales**	**Herramientas**	**Entregable**
1. Caracterizar datos	Revisar cobertura, duplicados, unidades, frecuencia y valores extremos, estudiar perfiles temporales, definir agregación horaria.	Python, pandas, SQL cuando aporte valor y visualización estadística.	Notebook analítico único, sección de calidad y exploración, diccionario de datos.
2. Comparar pronósticos	Definir baselines naive, aplicar validación de origen móvil, ejecutar AutoARIMA con selección automática en R y comparar regresores con machine learning.	R, paquete forecast, Python y scikit-learn.	Notebook analítico único, sección de modelado y reporte de métricas.
3. Evaluar picos	Definir el umbral usando solo entrenamiento, construir la etiqueta binaria y evaluar alertas, eventos omitidos y falsas alarmas.	Python, scikit-learn y métricas de clasificación.	Notebook analítico único, sección de alertas y resultados de clasificación.
4. Automatizar el flujo	Generar resultados estructurados, automatizar la inferencia y registrar errores, versiones y fecha de ejecución.	Python, R, Amazon S3, EventBridge Scheduler, Lambda o contenedor y CloudWatch.	Pipeline programado y registro de ejecuciones.
5. Visualizar y evaluar	Conectar los resultados, construir vistas funcionales, probar filtros y actualización, y mostrar incertidumbre y límites.	Power BI. Athena y ODBC solo si el volumen y la arquitectura lo justifican.	Dashboard funcional y evaluación integral del prototipo.

Tabla 2. Relación entre objetivos, actividades, herramientas y entregables

6. Plan de implementación

El proyecto avanzará por etapas con dependencias claras. No se fijan fechas para mantener el plan válido durante la ejecución y permitir que los resultados de la revisión de datos ajusten el detalle técnico.

Fase	**Trabajo**
1. Definición consultiva	Investigar el contexto energético, fijar usuario, problema, decisión operativa, hipótesis y alcance.
2. Revisión de antecedentes	Leer el estudio original y los trabajos relevantes, comparar datos, modelos, horizontes y métricas, delimitar la contribución aplicada.
3. Auditoría y exploración	Resolver la cobertura temporal, validar unidades, estudiar estacionalidad, perfilar las zonas y seleccionar la agregación.
4. Modelado y evaluación	Construir líneas base, comparar pronósticos, estudiar el aporte del clima, definir y evaluar alertas de demanda elevada.
5. Pipeline local y AWS	Modularizar la preparación y la inferencia, integrar Python y R, generar resultados reproducibles y validar el flujo local antes de seleccionar servicios cloud.

Fase	Trabajo
6. Dashboard e integración	Conectar los resultados con Power BI, diseñar vistas operativas, probar la actualización y presentar incertidumbre y limitaciones.
7. Validación integral	Revisar la exactitud histórica, el funcionamiento del pipeline, los errores, los costos de ejecución y las condiciones necesarias para un uso operativo real.

Tabla 3. Secuencia de implementación

7. Glosario

Backtesting temporal. Evaluación de un modelo en distintos periodos históricos, usando en cada pronóstico solo la información que habría estado disponible en ese momento.

Demanda estadísticamente elevada. Observación que supera un umbral construido con datos históricos. En este proyecto, no equivale por sí misma a sobrecarga ni a riesgo operativo.

Fuga de información. Uso de datos que no estarían disponibles al emitir una predicción y que hace que la evaluación parezca mejor de lo que sería en operación.

Horizonte de pronóstico. Periodo futuro para el que se producen predicciones. El alcance inicial considera hasta 168 horas, condicionado a la validación.

ARIMA y SARIMA. Familias de modelos de series temporales que utilizan valores pasados, diferencias y relaciones entre observaciones. SARIMA incorpora componentes estacionales.

SARIMAX. Extensión de SARIMA que permite incorporar variables explicativas externas.

MAE y RMSE. Métricas de error de pronóstico. MAE promedia los errores absolutos y RMSE da más peso relativo a los errores grandes.

Pipeline. Secuencia automatizada para obtener datos, validarlos, transformarlos, ejecutar modelos y guardar resultados.

Pronóstico meteorológico disponible. Previsión del tiempo obtenida antes del instante de consumo que se quiere pronosticar. Es distinta del clima observado posteriormente.

8. Referencias

Alsalem, K. (2025). A hybrid time series forecasting approach integrating fuzzy clustering and machine learning for enhanced power consumption prediction. Scientific Reports, 15, Article 6447. https://doi.org/10.1038/s41598-025-91123-8

Amendis. (s. f.). La distribution de l'électricité. https://www.amendis.ma/fr/nos-activites/nos-metiers/distribution-lelectricite

Amendis. (s. f.). La distribution d'électricité : principales réalisations. https://www.amendis.ma/fr/nos-activites/nos-principales-realisations/distribution-delectricite

Autorité Nationale de Régulation de l'Électricité. (2026, 30 de enero). L'ANRE approuve et publie la capacité d'accueil du système électrique national au titre de la période 2026 à 2030. https://anre.ma/actualites/lanre-approuve-et-publie-la-capacite-daccueil-du-systeme-electrique-national-au-titre-de-la-periode-2026-2030/

Amazon Web Services. (s. f.). What is Amazon EventBridge Scheduler? https://docs.aws.amazon.com/scheduler/latest/UserGuide/what-is-scheduler.html

Amazon Web Services. (s. f.). What is AWS Lambda? https://docs.aws.amazon.com/lambda/latest/dg/welcome.html

Amazon Web Services. (s. f.). Connecting to Amazon Athena with ODBC and Power BI. https://docs.aws.amazon.com/athena/latest/ug/connect-with-odbc-and-power-bi.html

Benhayoun, L., & Lakouismi, S. (2026). Artificial intelligence for energy forecasting in emerging economies: A machine learning case study from Morocco. Procedia Computer Science, 277, 3390 a 3399. https://doi.org/10.1016/j.procs.2026.02.375

Biswas, N., Mahdi, M. A., & Das Gupta, M. (2026). Electricity demand forecasting for Tetouan, Morocco using Darts in machine learning: A comparative study of forecasting models. Results in Engineering, 30, Article 110289. https://doi.org/10.1016/j.rineng.2026.110289

Microsoft. (s. f.). Refresh data in Power BI. https://learn.microsoft.com/en-us/power-bi/connect-data/refresh-data

Ministère de l'Économie et des Finances du Royaume du Maroc. (2025, 21 de abril). Reunión de la octava sesión del Consejo de Administración de la Oficina Nacional de Electricidad y Agua Potable. https://www.finances.gov.ma/es/Pages/detail-actualite.aspx?fiche=7243

Ministère de l'Économie et des Finances du Royaume du Maroc. (2026, 27 de julio). Board of Directors of the National Office of Electricity and Drinking Water. https://www.finances.gov.ma/en/Pages/detail-actualite.aspx?fiche=7799

Observatoire Régional de Veille Stratégique et d'Intelligence Territoriale. (2026). Les indicateurs vitaux de la région Tanger Tétouan Al Hoceïma. https://orvsit.crtta.ma/indicateurs-vitaux.php

Open Meteo. (s. f.). Weather forecast API documentation. https://open-meteo.com/en/docs

Salam, A., & El Hibaoui, A. (2018a). Comparison of machine learning algorithms for the power consumption prediction: Case study of Tetouan city. In 2018 6th International Renewable and Sustainable Energy Conference (IRSEC) (pp. 1 a 5). IEEE. https://doi.org/10.1109/IRSEC.2018.8703007

Salam, A., & El Hibaoui, A. (2018b). Power consumption of Tetouan City [Data set]. UCI Machine Learning Repository. https://doi.org/10.24432/C5B034

Shearer, C. (2000). The CRISP DM model: The new blueprint for data mining. Journal of Data Warehousing, 5(4), 13 a 22.